

CONCEPTION, DÉVELOPPEMENT ET DÉPLOIEMENT D'UN ASSISTANT CONVERSATIONNEL RAG BASÉ SUR LE MODEL CONTEXT PROTOCOL (MCP) POUR L'ACCÈS INTELLIGENT AUX DOCUMENTS MÉTIER DE LA DNSI (CERP) VIA SHAREPOINT

Aivancity School for Technology and Business, Villejuif, France

Jean Diriel NZE PGE5

Contexte Général et Problématique

1. La transformation numérique au sein de grandes structures telles que la DNSI (Direction du Numérique et des Systèmes d'Information) s'accompagne d'une accumulation massive de documentation technique et métier, principalement stockée sur des plateformes collaboratives comme SharePoint CERP. En l'absence de dispositifs d'interrogation sémantique avancés, l'accès à ce patrimoine informationnel repose essentiellement sur des mécanismes de consultation manuelle ou sur des fonctionnalités de recherche basiques, insuffisantes pour répondre à des besoins complexes et contextuels. Cette situation engendre une difficulté croissante à localiser rapidement une information pertinente et exploitable, ralentissant les processus opérationnels et décisionnels, et révélant un besoin clair d'outils d'accès à la connaissance plus intelligents et interactifs.

2. L'avènement des modèles de langage à grande échelle (LLMs) propose une nouvelle interface en langage naturel pour l'accès aux connaissances. Toutefois, leur intégration directe dans un environnement d'entreprise soulève des défis critiques de fiabilité et de sécurité. Les phénomènes d'hallucination inhérents aux modèles génératifs, couplés à leur méconnaissance des données privées de l'organisation (données absentes de leur corpus d'entraînement), imposent l'adoption d'architectures hybrides. Le défi scientifique consiste ici à concevoir un système capable d'interfacer ces modèles avec le corpus SharePoint privé de manière sécurisée, standardisée et vérifiable.

Revue de Littérature et État de l'Art

3. La littérature scientifique récente identifie l'architecture RAG (Retrieval-Augmented Generation) comme la solution de référence pour ancrer les réponses des LLMs dans une base de connaissances externe (Lewis et al., 2020). Cette approche combine un système de recherche d'information dense (Dense Retrieval) avec un générateur de texte, permettant une mise à jour des connaissances sans réentraînement coûteux du modèle. L'utilisation d'index vectoriels, tels que Faiss, permet une recherche par similarité sémantique nettement supérieure aux méthodes lexicales pour des questions ouvertes.

4. Cependant, l'intégration de sources de données hétérogènes (silos de données comme SharePoint) repose traditionnellement sur des connecteurs ad-hoc, fragiles et difficilement maintenables. L'état de l'art évolue vers une standardisation des interfaces entre les assistants IA et les sources de données, incarnée par l'émergence récente du *Model Context Protocol* (MCP). Ce protocole vise à normaliser la manière dont le contexte est exposé aux modèles, promettant une interopérabilité et une sécurité accrues par rapport aux solutions d'intégration propriétaires. L'étude de ce protocole dans un cadre applicatif réel constitue un axe de recherche novateur.

Proposition de Solution

5. Ce projet de fin d'études propose la conception d'une architecture RAG modulaire, fondée sur les principes du Model Context Protocol (MCP), pour permettre un accès unifié aux documents métier hébergés sur le SharePoint CERP. Le système est conçu pour agir comme un intermédiaire intelligent, récupérant le contexte pertinent via des mécanismes de recherche sémantique avant de le soumettre à un modèle de langage performant (Mistral AI). L'objectif est de garantir que chaque réponse générée soit sourcée et traçable, répondant aux exigences de rigueur de la DNSI.

6. La solution technique s'articule autour d'un pipeline de traitement avancé comprenant l'ingestion sécurisée des documents, leur segmentation et leur vectorisation. Une attention particulière est portée à l'authentification et à la gestion des droits, intégrant un mécanisme de SSO (Single Sign-On) pour assurer que l'assistant respecte les ACLs (Access Control Lists) définies dans SharePoint. Le prototype développé, dénommé "AntiGravity" en interne, sert de preuve de concept pour valider cette approche architecturale standardisée face aux contraintes réelles de production (proxy d'entreprise, latence, confidentialité).

Méthodologie et Architecture

7. La méthodologie de recherche adoptée est de type "Design Science Research", itérant entre la conception théorique et l'implémentation pratique. La première phase se concentre sur le développement des connecteurs compatibles MCP pour l'extraction et le pré-traitement des données non structurées (PDF, DOCX) issues de SharePoint. L'architecture logique sépare le serveur de contexte (gestion de l'index Faiss et des documents) du client conversationnel, favorisant une scalabilité horizontale et une maintenabilité accrue.

8. La phase de développement actuelle implémente l'interface utilisateur et la couche de sécurité. L'application, développée en Python (Streamlit), intègre des algorithmes de re-ranking et de classification de requêtes pour optimiser la pertinence des résultats. Le déploiement est prévu sur une infrastructure conteneurisée, respectant les normes de sécurité de l'entreprise. L'évaluation finale du système reposera sur des métriques quantitatives (précision du rappel documentaire) et qualitatives (satisfaction utilisateur, fluidité des réponses).

Conclusion et Apports Scientifiques

9. Cette première phase de conception confirme la pertinence du couplage entre l'architecture RAG et une approche standardisée de type MCP pour résoudre les problèmes d'accès à l'information en entreprise. Le modèle théorique élaboré permet de dépasser les limitations des connecteurs rigides, offrant une flexibilité nécessaire pour évoluer avec le système d'information de la DNSI. Les premiers tests valident la capacité du système à synthétiser des informations complexes issues de multiples documents SharePoint avec un taux d'hallucination minimal.

10. Au-delà de l'implémentation technique, ce travail contribue à la compréhension des enjeux d'intégration des IA génératives dans les écosystèmes "Enterprise IT" traditionnels. Il propose un cadre de référence pour le déploiement sécurisé d'assistants cognitifs, soulignant l'importance de la souveraineté des données et de l'interopérabilité des protocoles. Les développements futurs viseront à étendre la couverture du protocole à d'autres sources de données métier, renforçant ainsi l'intelligence collective de l'organisation.

Bibliographie

- [1] Lewis, P., et al. (2020). "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks". *Advances in Neural Information Processing Systems*, 33.
- [2] Anthropic (2024). "Model Context Protocol: An Open Standard for Connecting AI Systems to Data". *Technical Specification*.
- [3] Jiang, A., et al. (2023). "Mistral 7B". *arXiv preprint arXiv:2310.06825*.
- [4] Microsoft (2024). "SharePoint Online Architecture and Security Model". *Microsoft Technical Documentation*.
- [5] Johnson, J., Douze, M., & Jégou, H. (2019). "Billion-scale similarity search with GPUs". *IEEE Transactions on Big Data*.
- [6] Gao, Y., et al. (2024). "Retrieval-Augmented Generation for Large Language Models: A Survey". *arXiv preprint arXiv:2312.10997*.
- [7] Vaswani, A., et al. (2017). "Attention Is All You Need". *Advances in Neural Information Processing Systems*, 30.
- [8] Hevner, A. R., et al. (2004). "Design Science in Information Systems Research". *MIS Quarterly*, 28(1).
- [9] OpenAI (2023). "GPT-4 Technical Report". *arXiv preprint arXiv:2303.08774*.
- [10] ISO/IEC 27001 (2022). "Information security, cybersecurity and privacy protection". *International Organization for Standardization*.